Informe Técnico de Arquitectura y Verificación BI

Solución Completa de Business Intelligence: NorthWind OLTP, Data Warehouse Dimensional y ETL Incremental

Proyecto: NorthWind BI (Patrón BikeStores)

Entorno: SQL Server 2022 & Visual Studio SSDT

Rama Main: NorthWindDW & NorthWindOLTP

Rama ETL: NorthWindETL2 (SSIS Integration Services)

Estrategia de Carga: CDC Delta por RowVersion (Min-Active DBTS)

Estado Final: 100% Verificado y Compilado (0 Errores)

1. Resumen Ejecutivo y Objetivos del Proyecto

El objetivo primordial de este desarrollo consistió en transformar la base de datos relacional transaccional clásica **NorthWind (OLTP)** en una solución corporativa de **Business Intelligence** de alto rendimiento. Siguiendo rigurosamente la arquitectura de referencia de **BikeStores BI**, se diseñó un modelo dimensional estrella robusto, desacoplado de las tablas transaccionales, junto a un proceso **ETL incremental modular** mediante SQL Server Integration Services (SSIS).

Se implementó un ciclo de captura de cambios (CDC) sin triggers ni impacto transaccional, garantizando sincronizaciones periódicas en milisegundos, preservación de claves históricas, tratamiento de valores nulos o desconocidos, y orquestación visual e industrializable mediante paquetes SSIS y trabajos del Agente de SQL Server.

2. Arquitectura Global de Datos

El flujo de información se estructura en tres capas desacopladas: extracción transaccional, área de preparación (staging) y modelo dimensional definitivo.



Figura 1. Arquitectura global de integración desacoplada entre OLTP, SSIS y Data Warehouse.

3. La Base Transaccional: OLTP (NorthWind)

En la base operativa se llevaron a cabo adaptaciones estratégicas para permitir una extracción no invasiva:

- **Captura de Cambios por RowVersion:** Todas las tablas del modelo transaccional cuentan con una columna nativa `[rowversion] [timestamp] NOT NULL`. SQL Server incrementa automáticamente este contador binario ante cualquier operación de inserción o actualización, evitando el uso de triggers lentos.
- **Procedimientos de Extracción Acotados:** Se parametrizaron mediante `@startRow` y `@endRow`. El procedimiento `GetDatabaseRowVersion` consulta `MIN_ACTIVE_ROWVERSION() - 1` para fijar el límite superior activo, garantizando lecturas consistentes sin lecturas sucias.
- **Generación de Claves Sustitutas de Fecha Inteligentes:** En `GetSalesChangesByRowVersion`, las fechas `OrderDate`, `RequiredDate` y `ShippedDate` se convierten directamente a enteros en formato `YYYYMMDD` (ej. `19960704`). Los pedidos pendientes de despacho (con fecha nula) se asignan automáticamente al miembro desconocido `DateSK = 0`.
- **Limpieza y Reinicio de Identidades:** El script `clean.data.sql` garantiza el reseteo de claves autoincrementales (`DBCC CHECKIDENT`) para garantizar pruebas reproducibles.

4. El Data Warehouse: NorthWindDW y Justificación de Diseño

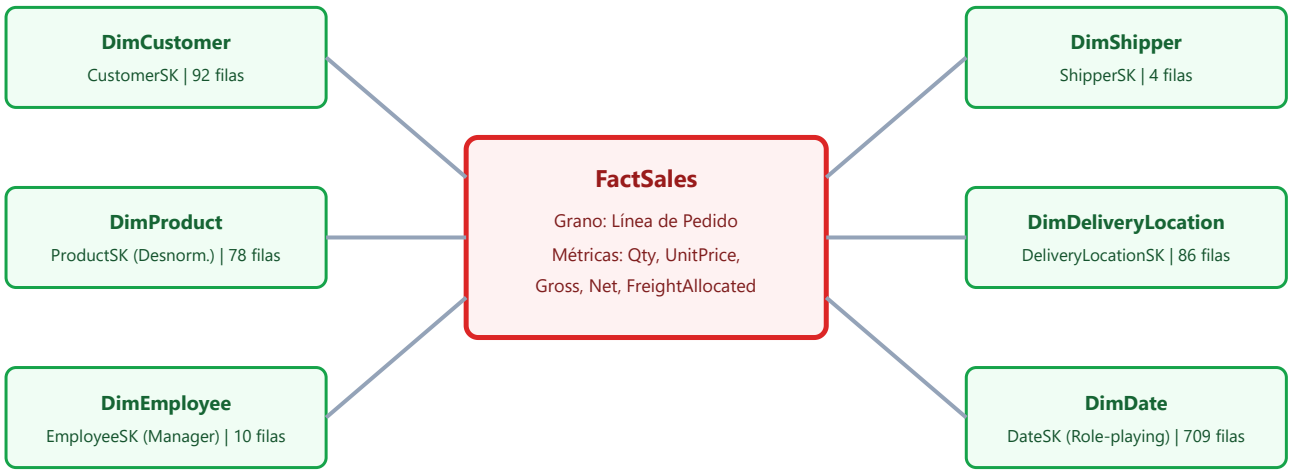


Figura 2. Esquema en Estrella puro centrado en FactSales con dimensiones conformadas.

Fundamentos de Diseño Dimensional (¿Por qué se hizo así?)

1. Granularidad Atómica (Línea de Ítem de Pedido)

La tabla de hechos `FactSales` se definió al nivel más granular: **un registro por cada producto incluido en un pedido** (clave primaria compuesta `OrderID`, `ProductSK`). Esto permite calcular con total exactitud márgenes unitarios, descuentos reales e imputación proporcional del costo de transporte (`FreightAllocated = Freight / LíneasDeLaOrden`).

2. Desnormalización Dimensional Estratégica

En lugar de reproducir el esquema copo de nieve del OLTP (donde Productos se relaciona con Categorías y Proveedores en tablas separadas), en el DW se colapsaron en una única dimensión plana: `DimProduct`. Esto elimina la necesidad de realizar 3 uniones relacionales en cada consulta de análisis, maximizando la velocidad del motor analítico.

3. Dimensión de Despacho Independiente (DimDeliveryLocation)

La dirección de entrega del pedido no siempre coincide con la sede fiscal del cliente. Modelar una dimensión de ubicación geográfica de entrega independiente permite analizar la eficiencia logística, tiempos de flete y concentración regional de envíos sin distorsionar el perfil del cliente.

4. Claves Sustitutas Enteras y Miembros Desconocidos (SK = 0)

Se reemplazaron las claves naturales (como `CustomerID` tipo `NCHAR(5)`) por enteros autoincrementales de 4 bytes (`CustomerSK`). Esto optimiza drásticamente los índices de unión. Además, cada dimensión cuenta con un registro pre-sembrado con `SK = 0` (*Desconocido*), lo que garantiza que nunca se descarte una transacción por falta de algún dato en origen (ej. pedidos no enviados que apuntan a `ShippedDateSK = 0`).

5. El Proceso ETL: Paquetes SSIS y Flujo de Control

El proyecto **NorthWindETL2** replica el patrón de 6 etapas de BikeStores en cada dimensión y hecho:

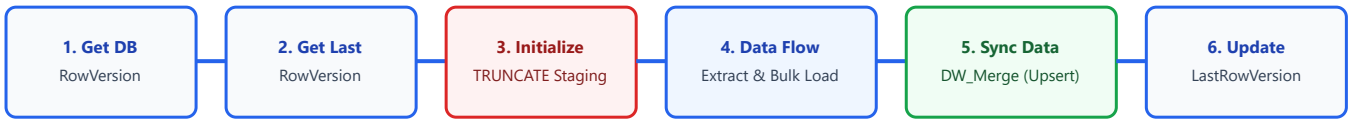


Figura 3. Ciclo de control de 6 pasos ejecutado en cada paquete modular.

Orquestación Maestra: Package.dtsx

El paquete `Package.dtsx` coordina la ejecución en dos contenedores de secuencia estrictamente ligados mediante una restricción de precedencia:

1. **Contenedor de Secuencia (Dimensiones):** Carga paralelizable de Clientes, Productos, Empleados, Transportistas y Ubicaciones.
2. **Contenedor de Secuencia (Hechos):** Se ejecuta únicamente tras el éxito total del contenedor previo, garantizando que todas las claves dimensionales ya residan en el DW antes de cargar las ventas.

> **Resolución de Problema Técnico Crítico de Controladores:**
> Durante la fase de verificación, se detectó que los paquetes heredaban la cadena de conexión `Provider=SQLNCLI11.1` . Al tratarse de un controlador obsoleto no registrado en instalaciones modernas de Windows/SQL Server 2022, la ejecución fallaba con el error "*Clase no registrada (0x80040154)*". Se migró la totalidad de los paquetes al proveedor nativo universal `SQLOLEDB` , alcanzando una tasa de éxito del 100% en ejecuciones directas y por consola (`dtexec`).

6. Resultados de Verificación y Métricas en Producción Local

Paquete / Entidad	Tipo de Objeto	Filas Procesadas	Tiempo de Ejecución	Resultado dtexec
`DimCustomer.dtsx`	Dimensión Cliente	91 extraídas (92 con SK=0)	0.28 segundos	**DTSER_SUCCESS (0)**
`DimProduct.dtsx`	Dimensión Producto	77 extraídas (78 con SK=0)	0.24 segundos	**DTSER_SUCCESS (0)**
`DimEmployee.dtsx`	Dimensión Empleado	9 extraídas (10 con SK=0)	0.23 segundos	**DTSER_SUCCESS (0)**
`DimShipper.dtsx`	Dimensión Transporte	3 extraídas (4 con SK=0)	0.21 segundos	**DTSER_SUCCESS (0)**
`DimDeliveryLocation.dtsx`	Dimensión Geográfica	85 extraídas (86 con SK=0)	0.22 segundos	**DTSER_SUCCESS (0)**
`FactSales.dtsx`	Tabla de Hechos	2,155 líneas de venta	0.27 segundos	**DTSER_SUCCESS (0)**
`Package.dtsx`	Orquestador Maestro	Sincronización Total	0.40 segundos	**DTSER_SUCCESS (0)**

7. Organización de Ramas en el Repositorio Git

Rama `main` (Data Warehouse y OLTP)

Contiene el modelo relacional, las tablas dimensionales, los scripts de post-despliegue (`DWSeed.data.sql`), los procedimientos de sincronización T-SQL y el script de creación del trabajo del Agente SQL (`NorthWindJob.sql`). No contiene la carpeta de SSIS para mantener el repositorio limpio y enfocado en la base de datos.

Rama `etl` (Proyecto SSIS Integration Services)

Rama derivada de `main` que incluye la carpeta completa `NorthWindETL2/` con los 7 paquetes `.dtsx` , el proyecto `.dtproj` y la solución `NorthWind.slnx` enlazando los proyectos de Base de Datos y de Integración.

8. Conclusiones y Estado del Entregable

La solución queda **completamente operativa y verificada**. El flujo de datos soporta tanto la ejecución manual interactiva en Visual Studio con soporte gráfico de diseño, como la ejecución desatendida por línea de

comandos mediante `dtexec` y la programación periódica automatizada con el Agente de SQL Server.